


DTW – Dynamic Time Warping

Dynamiczna transformata czasowa (ang. Dynamic Time Warping), opracowana w latach 60-tych [5], jest algorytmem wykorzystywanym do mierzenia podobieństwa między dwoma sekwencjami sygnałów czasowych o różnej długości. Był to algorytm intensywnie wykorzystywany do rozpoznawania mowy [88], [97]. Metoda ta poza rozpoznawaniem mowy stosowana jest także w systemach wideo oraz grafice. Potrafi ona wychwycić podobieństwa np. w dwóch wypowiedziach tego samego słowa, nawet jeśli zostały wypowiedziane z różną szybkością. W rzeczywistości każde dane, które mogą być zamienione w postać liniową mogą być później analizowane z wykorzystaniem DTW. Najczęściej używaną miarą odległości w algorytmie DTW jest miara euklidesowa, choć możliwe jest stosowanie praktycznie dowolnej miary odległości. Proces optymalizacji korzysta z programowania dynamicznego (ang. Dynamic Programming – DP), o czym świadczy także nazwa algorytmu – Dynamic Time Warping. Technika DTW miała swoją genezę w izolowanym rozpoznawaniu słów (IWR, ang. Isolated-word re-cognition), w którym słowa są celowo mówione z przerwami jedno po drugim, została też zastosowana w ograniczony sposób do rozpoznawania mowy ciągłej (CSR, ang. Continuous Speech Recognition). W przypadku porównywania dłuższych wzorców, znacznie rośnie nakład obliczeniowy oraz spada skuteczność działania algorytmu, dla tego też obecnie odchodzi się od stosowania tej metody do rozpoznawania mowy, zastępując ją np. Ukrytymi Modelami Markowa.

Algorytm DTW [57, 87, 88, 97, 104] jest niezwykle efektywny w mierzeniu podobieństwa sygnałów w dziedzinie czasu. Minimalizuje skutki przesunięć i zniekształceń sygnałów poprzez „elastyczną” transformację sygnału czasowego, co pozwala na znajdowanie podobnych kształtów o różnych fazach.

Mając dwa szeregi czasowe $X = (x_1, x_2, \dots, x_N), N \in \mathbb{N}$ i $Y = (y_1, y_2, \dots, y_M), M \in \mathbb{N}$, optymalne rozwiązanie znajduje się w czasie $O(N \cdot M)$. Ten koszt obliczeniowy można zmniejszyć poprzez np. wyeliminowanie pewnej podprzestrzeni rozwiązań (ang. search subspace).



Rysunek 4.1. Dwa różne przebiegi czasowe i dopasowanie DTW. Źródło: 57.

Na rys. 4.4 A) Przedstawiono dwa przebiegi czasowe, które mogą być porównane algorytmem DTW. Rys. 4.4 B) przedstawia dopasowanie obu przebiegów za pomocą algorytmu DTW.

Jeśli podane szeregi mają wartości w przestrzeni cech Φ , to aby porównać dwa różne szeregi $X, Y \in \Phi$, musimy mieć lokalną miarę odległości, którą należy definiować jako funkcję:

$$d: \Phi \times \Phi \rightarrow \mathbb{R} \geq 0 \quad (4.1)$$


Miara ta powinna mieć małe wartości gdy szeregi są podobne i duże gdy się różnią. Bazując na Programowaniu Dynamicznym, lokalną miarę odległości traktujemy jako funkcję kosztu, a zadanie opty-

malnego dopasowania szeregów jako zadanie znalezienia odpowiedniej sekwencji punktów poprzez minimalizację właśnie tej funkcji kosztu.

Pierwszym krokiem algorytmu jest zbudowanie macierzy lokalnych odległości $C \in \mathbb{R}^{N \times M}$, która reprezentuje odległości pomiędzy wszystkimi parami elementów szeregów X i Y . Jest to lokalna macierz kosztu, określana też jako macierz odległości lokalnych:

$$C_l \in \mathbb{R}^{N \times M} : c_{nm} = \|x_n - y_m\|, n \in [1:N], m \in [1:M] \quad (4.2)$$


Rys. 4.5 przedstawia macierz odległości lokalnych dla przebiegów czasowych przedstawionych także na rysunku. Odległości pomiędzy próbkami przebiegów liczone są za pomocą metryki Manhattan. Mały koszt oznaczony jest ciemnym kolorem, a duży koszt porównania sygnałów to obszary jasne.



Rysunek 4.2. Macierz odległości lokalnych. Źródło: 87.

Po zbudowaniu macierzy odległości lokalnych, kolejnym krokiem jest znalezienie ścieżki dopasowania (zgodności) (ang. warping path) przebiegającej przez obszary o małym koszcie. Ścieżka ta definiuje dopasowanie elementu $x_n \in X$ do $y_m \in Y$ i jest kosztem dopasowania obu przebiegów. Ścieżka ta rys. 4.6 jest zbiorem punktów:


$$p = (p_1, p_2, \dots, p_k) \text{ gdzie } p_l = (p_n, p_m) \in [1:N] \times [1:M], l = [1:K] \quad (4.3)$$



Rysunek 4.3. Optymalna ścieżka dopasowania. Źródło: 87.

Optymalna ścieżka dopasowania musi spełniać następujące warunki:

1. Warunek granicy: $p_1 = (1,1)$ oraz $p_K = (N,M)$. Pierwsze punkty przebiegów X i Y oraz ostatnie punkty tych przebiegów są dopasowane do siebie. Warunek ten zapewnia, że dopasowane są do siebie całe przebiegi.
2. Warunek monotoniczności: $n_1 \leq n_1 \leq \dots \leq n_K$ i $m_1 \leq m_1 \leq \dots \leq m_K$. Warunek zapewnia odpowiednią synchronizację przebiegów. Oznacza to, że żaden z przebiegów nie będzie cofał się w czasie w procesie dopasowywania.
3. Warunek długości kroku. Oznacza on, że kolejne punkty ścieżki dopasowania nie mogą wykonywać zbyt długich skoków na dopasowywanych przebiegach. Zapewnia, że żaden element przebiegów X i Y nie będzie pominięty. Jest kilka metod znajdowania kolejnych punktów ścieżki, natomiast podstawowy tzw. „wzorzec kroku” to punkty ze zbioru $p_{l+1} - p_l \in \{(1; 1); (1; 0); (0; 1)\}$. Podstawowy wzorzec kroku przedstawiony jest graficznie na rys 4.7.



Rysunek 4.4. Wzorzec kroku w procesie znajdowania optymalnej ścieżki dopasowania.

Koszt dopasowania związany z konkretną ścieżką dopasowania jest sumą lokalnych odległości na tej ścieżce:

$$C_p(X, Y) = \sum_{l=1}^K c(x_{n_l}, y_{m_l}) \quad (4.4)$$

Ścieżka o minimalnym koszcie jest optymalną ścieżką dopasowania. Aby uniknąć sprawdzania wszystkich ścieżek w celu znalezienia optymalnej, algorytm DTW korzysta właśnie z Programowania Dynamicznego. W tej części algorytmu wykorzystywana jest tzw. Funkcja Odległości DTW (ang. DTW distance function). Jeśli optymalną ścieżkę dopasowania oznaczmy przez P^* , to:

$$DTW(X, Y) = c_{P^*}(X, Y) = \min \{c_p(X, Y), p \in P^{N \times M}\} \quad (4.5)$$

gdzie $P^{N \times M}$ jest zbiorem wszystkich możliwych ścieżek dopasowania. Za pomocą tej funkcji możemy zbudować tzw. globalną macierz kosztu, określaną też jako macierz odległości globalnych, definiując elementy tej macierzy jako:

$$D(n, m) = DTW(X(1:n), Y(1:m)) \quad (4.6)$$

W tym miejscu programowanie dynamiczne pozwala obliczyć macierz kosztu globalnego w sposób efektywny, w czasie $O(N \cdot M)$:

1. Wiersz nr 1:

$$D(1, m) = \sum_{k=1}^m c(x_1, y_k), m \in [1, M] \quad (4.7)$$

2. Kolumna nr 1:


$$D(n, 1) = \sum_{k=1}^n c(x_k, y_1), n \in [1, N] \quad (4.8)$$

3. Pozostałe elementy macierzy:

$$D(n, m) = \min \{D(n-1, m-1), D(n-1, m), D(n, m-1)\} + c(x_n, y_m) \quad (4.9)$$

gdzie: $n \in [1, N], m \in [1, M]$

Wzór 4.10 pokazuje, jak obliczyć kolejne elementy macierzy na podstawie elementów obliczonych wcześniej oraz aktualnego kosztu lokalnego, co jest właśnie programowaniem dynamicznym. Zastosowany tu wzorec kroku jest to właśnie podstawowy wzorec z rys. 4.7. Mając już macierz kosztu globalnego, optymalną ścieżkę dopasowania znajdujemy wracając od końca macierzy, czyli punktu $D(N, M)$ do punktu $D(1, 1)$ poprzez sąsiednie punkty o najmniejszej wartości. W pracy 87 podany jest dowód na otrzymanie w ten sposób optymalnej ścieżki dopasowania. Macierz kosztu globalnego oraz optymalna ścieżka dopasowania przedstawiona jest na rys. 4.8.



Rysunek 4.5. Macierz kosztu globalnego i optymalna ścieżka dopasowania. Źródło: 87.

DTW opisane także w moim doktoracie. Dostępny na mojej stronie w sekcji publikacje.

5. Bellman R., Kalaba R., "On adaptive control processes", Automatic Control, IRE Transactions on, 1959, vol. 4, no. 2, pp. 1–9.
57. Keogh E.J., Pazzani M.J., "Derivative dynamic time warping", the 1st SIAM International Conference on Data Mining (SDM-2001), Chicago, IL, USA.
87. Müller M., "Information Retrieval for Music and Motion", Springer Berlin Heidelberg, part I, chapter 4 "Dynamic Time Warping", 2007, pp. 69 – 74.
88. Myers C.S., Rabiner L.R. "A comparative study of several dynamic time-warping algorithms for connected word recognition", The Bell System Technical Journal, September 1981, Vol. 60, 7, pp. 1389 – 1409.
97. Rabiner L.R., Rosenberg A., Levinson S., "Considerations in dynamic time warping algorithms for discrete word recognition", IEEE Transactions Acoustic Speech Signal Process, 1978, Vol. 26, 6, pp. 575 – 582.

104. Salvador S., Chan P., "*FastDTW: Toward Accurate Dynamic Time Warping in Linear Time and Space*", KDD Workshop on Mining Temporal and Sequential Data, pp. 70-80, 2004.