

Współczynniki cepstralne

Cepstrum zostało zdefiniowane w 1963 r. przez Bogerta, Healy'ego i Tukey'a. Operacja cepstrum oparta jest o transformację Fouriera (spectrum), stąd jej nazwa – cepstrum. Rezultatem jest przebieg pseudoczasowy, kolejne wartości na osi rzędnych można interpretować jako jednostki czasu, natomiast wartości z osi odciętych związane są w pewien sposób z autokorelacją i na ich podstawie można wyznaczyć ton podstawowy. Analizowany sygnał zostaje poddany transformacji Fouriera, a następnie przekształcany jest do skali logarymicznej. Wynik poddaje się drugiej transformacji Fouriera, wracając w ten sposób w dziedzinę czasu i otrzymując w ten sposób sygnał cepstrum (4.1). Do wyznaczenia tonu podstawowego potrzebne jest natomiast cepstrum rzeczywiste, czyli wartość bezwzględna tego sygnału (4.2).

$$c(\tau) = F^{-1}(\log F(s(t))) \quad (4.1)$$


$$C(\tau) = F^{-1}(\log |F(s(t))|) \quad (4.2)$$

Szacowanie częstotliwości podstawowej odbywa się na podstawie zależności:

$$f_0 = \frac{1}{\tau_{\max}}, \quad C(\tau_{\max}) = \max_{\tau} C(\tau) \quad (4.3)$$

F_0 wyznacza się na podstawie maksima lokalnego rzeczywistego sygnału cepstrum w przedziale od 50 Hz do 400 Hz, gdyż w takim zakresie należy spodziewać się częstotliwości tonu krztaniowego.

Poniższy rysunek przedstawia alofon a0072 przedstawiony w dziedzinie czasu, oraz jego cepstrum. Przedstawione jest ono w granicach od 55 do 441 próbek, co odpowiada właśnie częstotliwości od 50 Hz do 400 Hz przy częstotliwości próbkowania sygnału $F_s = 22050$ Hz. Częstotliwość tonu podstawowego obliczona na podstawie wsp. cepstrum wynosi 107,56 Hz.



Rysunek 4.1. Cepstrum sygnału mowy.

Skale perceptualne

Prawo Webbera-Fechnera mówi, że reakcja układu biologicznego jest proporcjonalna do logarytmu pobudzającego go bodźca.


Można więc stwierdzić, że subiektywne wrażenie człowieka nie zależy w prosty sposób od obiektywnie mierzalnego pobudzenia. Oznacza to, że ludzkie ucho nie odpowiada liniowo na zwiększającą się częstotliwość.

Skala melowa

Wyznaczona w oparciu o tony proste. Odpowiada subiektywnemu wrażeniu wysokości dźwięku. W wyniku doświadczenia okazało się, że wrażenie wysokości zależy również od głośności dźwięku, stąd w definicji przyjęto poziom 40dB SPL (Sound Pressure Level) (względem 20μPa).

Skala melowa wg Beranka (1000 mel = 1000 Hz)


$$M = 1127 \cdot \ln\left(1 + \frac{f}{0.7}\right)$$



$$M = 2595 \cdot \log_{10}\left(1 + \frac{f}{700}\right)$$

Parametry Mel-cepstralne MFCC (ang. Mel-Frequency Cepstral Coefficients)

Parametry mel-cepstralne powstają z cepstrum sygnału przedstawionego w skali melowej (mel-cepstrum). Skalę melową uzyskuje się poprzez filtrację sygnału bankiem filtrów o charakterystyce trójkątnej. K-ty współczynnik mel-cepstralny odpowiada zawartości k-tego pasma. Liczba pasm wynosi od 12 do 20.



$$\begin{bmatrix} MFCC_1 \\ MFCC_2 \\ MFCC_3 \\ MFCC_4 \\ \vdots \\ MFCC_k \end{bmatrix}$$

Wektor parametrów mel-cepstralnych to wektor współczynników cepstrum w odpowiednich pasmach melowych. Mają za zadanie odzwierciedlać naturalną odpowiedź układu słuchowego na pobudzenie dźwiękami mowy. Parametry mel-cepstralne cechuje mała wrażliwość na szum.



Rysunek 3.4: Schemat algorytmu obliczania współczynników MFCC

Algorytm obliczania współczynników przedstawia rysunek 3.4. Na początku działania algorytmu sygnał mowy podlega procesowi preemfazy, czyli filtracji formującej, która osłabia składowe o małych częstotliwościach, a wzmacnia składowe o wysokich częstotliwościach. Proces preemfazy przedstawia wzór

$$x'_n = x_n - a x_{n-1},$$

gdzie x_n i x'_n to odpowiednio sygnał przed i po preemfazie oraz a zwykle przyjmowane jest jako 0.97.

Kolejnym etapem jest ramkowanie sygnału czyli podział sygnału na krótkie fragmenty zwane ramkami (*frames*). Możliwe jest zastosowanie nakładania się kolejnych ramek czasowych (*overlap*). Następnie wykonywane jest okienkowanie (*windowing*) z zastosowaniem okna Hamminga

$$Ham(N) = 0.54 - 0.46 \cos\left(2\pi \frac{n-1}{N-1}\right),$$

gdzie N to długość ramki, a $n = 1, 2, \dots, N$. Każda z ramek zostaje poddana działaniu FFT w celu uzyskania widma mocy $|FFT|^2$ bądź też widma amplitudowego $|FFT|$ w zależności od implementacji algorytmu. Uzyskane widmo zostaje poddane działaniu zestawu filtrów H_m . Ilość filtrów oraz ich kształt różni się w zależności od implementacji algorytmu, jednak najczęściej spotykanymi w literaturze są filtry trójkątne, których środki są równomiernie rozmieszczone w danym zakresie częstotliwości w skali mel. Przykładowy zestaw filtrów przedstawia rysunek. Na wyjściu każdego z filtrów otrzymywana jest energia pasma według wzoru

$$S_m = \sum_{k=1}^N |X_r(k)|^2 H_m(k),$$

gdzie m to numer filtra, a X_r widmo ramki.

W dalszych obliczeniach używany jest logarytm energii, co pozwala na zredukowanie wrażliwości filtrów na bardzo głośne i bardzo ciche dźwięki oraz modelowanie nieliniowej amplitudowej wrażliwości ucha ludzkiego. Ponadto stosowanie logarytmu znacząco wpływa na jakość rozpoznawania [28]. Ostatnim etapem algorytmu jest zastosowanie dyskretnej transformaty kosinusowej (DCT). Końcowe wartości współczynników MFCC obliczane są jako

$$c_i = \sqrt{\frac{2}{M}} \sum_{m=1}^M \log(S_m) \cos\left(\frac{\pi i}{M}(m-0.5)\right),$$

gdzie i jest numerem współczynnika, a M to liczba użytych filtrów. W większości systemów rozpoznawania i przyjmuje wartości od 1, a współczynnik c_0 jest pomijany. Często do uzyskanych współczynników dołączany jest za to logarytm energii ramki

$$E = \log\left(\sum_{k=1}^N x_k^2\right).$$